# Alejandro Ortiz Perdomo

## AI Engineer | Machine Learning Engineer

Bogotá, Colombia | +57 319 666 3193 | alejortizp@gmail.com
LinkedIn: linkedin.com/in/alejandro-ortiz-perdomo-a35348116 | GitHub: github.com/alejortizp | Portafolio: alejortizp.github.io/curriculum_HV

## RESUMEN PROFESIONAL

AI Engineer con experiencia productizando soluciones de **GenAI/RAG** y **Agentic AI** en **Azure** y **GCP**. Especializado en diseño e implementación de **agentes inteligentes** (**LangChain**, **Azure OpenAI**, agentes **SRPA**) y arquitecturas de referencia para clientes enterprise. Track record procesando **10k+ consultas/mes** con agentes conversacionales y pipelines de matching semántico con **95%** de precisión. Combino Maestría en Ingeniería de Software (en curso) con base en Estadística para diseñar sistemas de IA escalables y listos para producción.

## EXPERIENCIA LABORAL

### AI Engineer - Torre IA

Periferia IT Group
06/2025 - Actualidad

- **Plataforma de Agentes IA (SRPA) para el SDLC:** Diseño técnico, conceptualización y documentación de un ecosistema propietario de agentes *Single-Responsibility Plug-and-play* que automatiza el ciclo de desarrollo end-to-end (onboarding, historias de usuario, asistencia en IDE, pruebas unitarias multi-lenguaje con cobertura >=**85%**, QA, documentación y asistentes técnicos sobre LLMs como **DeepSeek R-1** en **Azure AI Foundry**). Plataforma multi-cloud (**Azure / AWS / GCP**) usada interna y comercialmente, con ramp-up **-70%** y ahorro de **60-70%** en el ciclo de desarrollo.
- **Sistema de Matching CV-Oferta:** Pipeline con **Azure Document Intelligence** + **AI Search** que procesa 500+ CVs/día con **95%** de precisión en extracción y búsqueda semántica vectorial que reduce screening en **70%**. Productivo con **10k+ búsquedas/mes** y latencia <200ms.
- **Pre-ventas y Arquitectura de Soluciones:** Construyo estimaciones técnicas, dimensionamiento de equipos y arquitecturas de referencia para soluciones de **GenAI, Agentic AI y RAG** en clientes enterprise (banca, seguros, retail, energía y telco). Lidero discovery técnico con stakeholders y posicionamiento del portafolio de agentes en anexos técnicos comerciales.

### AI Engineer Freelance - Clínica Odontológica

Freelance
07/2026 - 08/2026

- **Agentes IA sobre WhatsApp:** Diseñé y desarrollé como único ingeniero dos agentes con **LangGraph** + **Azure OpenAI**: agendamiento de citas sincronizado con **Outlook (Microsoft Graph)**, con clasificación de intención por LLM y escalamiento de casos complejos; y recordatorios por categoría clínica con aprobación humana (*human-in-the-loop*).
- **Guardrails deterministas y despliegue serverless:** El LLM solo interpreta; la reserva la ejecuta código determinista con bloqueo que evita la doble reserva. Desplegado en **Azure Functions** (colas con poison-queue y deduplicación), Table Storage, **Key Vault** con managed identity y alertas en Application Insights; webhook de **WhatsApp Cloud API** con verificación HMAC. Desarrollo TDD con **118 tests**.

### Machine Learning Engineer

Global Hitss
09/2023 - 06/2025

- **GenAI & RAG:** Diseñé e implementé agente conversacional con RAG que redujo tickets de soporte en **40%**, procesando **10k+ consultas/mes** con 85% de resolución sin escalamiento. Stack: LangChain, Azure OpenAI, FAISS.
- **MLOps:** Implementé pipeline CI/CD en **Databricks + MLflow** que redujo tiempo de deployment de 2 semanas a **2 días**. Modelos en producción con monitoreo automático de drift y reentrenamiento.
- **Reinforcement Learning:** Productivicé sistema *Next Best Offer* (NBO) con A/B testing que incrementó conversión en **15%** y revenue de **$10k por persona**.

• **Modelo de Churn:** Desarrollé modelo predictivo con **Lift de 3.0** y recall del 82% en top decil, integrado a CRM para retención proactiva. Impactó **50k+ clientes**.

### Consultor Machine Learning
Grupo CINTE
08/2023 - 09/2023

• **Observabilidad ML:** Diseñé metodología integral de monitoreo para detección de *data/model drift* con alertas automáticas de reentrenamiento, adoptada como estándar del equipo de ciencia de datos.
• **Optimización:** Audité y optimicé algoritmos LightGBM y Random Forest, mejorando eficiencia computacional y reduciendo tiempos de inferencia.

### Data Scientist
NAE
03/2023 - 07/2023

• **Modelo de Contactabilidad:** Desarrollé modelo con **LightGBM** que incrementó tasa de contacto efectivo en **60%** (de 25% a 40%), optimizando ventanas horarias y canales. Impactó campañas con **100k+ contactos/mes**.

### Data Scientist II
Xolit
05/2022 - 01/2023

• **Modelo de Propensión de Pago:** Desarrollé modelo predictivo de probabilidad de pago y acuerdo de cartera, maximizando el recaudo mediante **focos automáticos** de gestión priorizados por propensión.
• **Sistema de Recomendación:** Implementé motor de recomendación de franja horaria óptima de contacto por titular, incrementando la efectividad de la gestión de cobranza.
• **Segmentación de Clientes:** Diseñé estrategia de marketing basada en clustering de titulares, permitiendo comunicación personalizada por segmento para optimizar tasas de recaudo.
• **Monitoreo:** Construí dashboards en **Power BI** para seguimiento de KPIs de recaudo y métricas de desempeño de modelos en producción.

### Analista de Datos / BI
Savia Salud EPS
08/2018 - 04/2021

• **Business Intelligence:** Desarrollé dashboards estratégicos en **Qlik Sense** para toma de decisiones, brindando visibilidad de KPIs operacionales y financieros a stakeholders clave.
• **Pipelines ETL:** Diseñé y construí procesos ETL para consolidar datos de múltiples fuentes, garantizando integridad y trazabilidad de la información.
• **Gestión de Requerimientos:** Lideré levantamiento de requerimientos técnicos y funcionales con usuarios clave, alineando soluciones BI con objetivos organizacionales.

## EDUCACIÓN

### Maestría en Ingeniería de Software
Universidad de los Andes
2025 - En proceso

### Estadístico
Universidad del Valle
2011 - 2016

• Diplomado Ciencia de Datos (DS4A) - Correlation One, 2022
• Diplomado Deep Learning - Univ. Autónoma Occidente, 2023

## CERTIFICACIONES

• AI-102: Microsoft Certified Azure AI Engineer Associate - Microsoft, Feb 2026
• NLP Specialization (RAG/Transformers) - Coursera, Jun 2025
• PyTorch Ultimate - Coursera, Mar 2025

• MLOps y Databricks - Netec, Dic 2024
• AWS Cloud Practitioner - Udemy, Feb 2022

## HABILIDADES TÉCNICAS

- **GenAI & LLMs:** LangChain (Agents, RAG), LangGraph, Azure OpenAI (GPT-4, Embeddings), Prompt Engineering, Vector DBs (FAISS, Qdrant, Pinecone), LLM Evaluation (RAGAS)
- **Azure AI & Cloud:** Azure AI Search, Document Intelligence, Azure AI Foundry, Azure Functions, Databricks + MLflow (Workflows, Model Registry), Delta Lake, Unity Catalog
- **Google Cloud Platform (GCP):** Vertex AI (Training, Endpoints, Pipelines), Cloud Run, Pub/Sub, Compute Engine (MIG zonales), Cloud Storage, Cloud SQL
- **Amazon Web Services (AWS):** EKS, Lambda, DynamoDB, SNS, SQS, RDS
- **ML/DL Frameworks:** PyTorch, TensorFlow, Scikit-learn, XGBoost, LightGBM, Hugging Face Transformers
- **MLOps & Engineering:** Python, SQL, PySpark, Docker, CI/CD, Apache Airflow, Kubernetes, Terraform, Go, Angular, Kotlin, FastAPI, Streamlit, Git, GitHub Actions

## HABILIDADES BLANDAS

Comunicación efectiva, Resolución de problemas, Pensamiento analítico, Trabajo en equipo, Adaptabilidad, Aprendizaje continuo, Gestión del tiempo, Liderazgo técnico

## IDIOMAS

- Español: Nativo
- Inglés: Profesional (B2)

## PROYECTOS

### Asistente RAG con Web Scraping y Evaluación RAGAS

github.com/alejortizp/rag-banco
Asistente conversacional sobre el sitio público de un banco: crawler que respeta robots.txt, indexación en **Qdrant**, reranking con cross-encoder y memoria por sesión. Evaluado con **RAGAS** (50 preguntas, juez LLM independiente): faithfulness **0.87**; el reranker mejoró context utilization en **+8 pts** (A/B).
Tecnologías: Qdrant, Sentence-Transformers, Cross-Encoder, Groq Llama 3.1, RAGAS, Streamlit, Docker

### Agente Email con LangChain

github.com/alejortizp/email-agent
Agente inteligente que consulta emails vía IMAP, clasifica con LLM y genera respuestas contextuales automáticas. Reduce tiempo de respuesta en **80%**.
Tecnologías: LangChain, Azure OpenAI, IMAP, Python, Prompt Engineering

### NL-to-SQL/Pandas Agent

github.com/alejortizp/nl-to-code
Agente que traduce lenguaje natural a queries SQL y operaciones Pandas. Incluye validación de código, ejecución segura en sandbox y visualización automática de resultados.
Tecnologías: LangChain, SQL, Pandas, Code Interpreter, ReAct Pattern

## PROYECTOS ACADÉMICOS

### Plataforma de Monitorías en GCP (Go + Angular)

MISW4204 Desarrollo de Soluciones Cloud - 2026 - Universidad de los Andes
Principal contribuidor (**60%** de commits, equipo de 4). Migré el sistema de Docker Compose a **MIG con autoscaling + Load Balancer** y luego a **Cloud Run + Pub/Sub** serverless, con reportes PDF generados por IA de forma asíncrona. Pruebas de carga JMeter: **158 rps** (p95 292 ms) con **0%** errores de infraestructura; cobertura **84%** (Go) y **93%** (Angular); SonarQube A.
Tecnologías: Go (Gin), Angular, PostgreSQL, Cloud Run, Pub/Sub, Cloud SQL, OpenAI, JMeter, SonarQube, GitHub Actions

### Marketplace de Envíos Event-Driven en AWS

MISW4301 Desarrollo de Apps en la Nube - 2026 - Universidad de los Andes
Lideré la arquitectura AWS e IaC de **11 microservicios** FastAPI (arquitectura hexagonal) sobre **EKS**, con extensión serverless: **SNS -> SQS** con DLQ, **4 Lambdas** en contenedor y DynamoDB, todo en **Terraform** desplegado con GitHub Actions a 5 ambientes. Resolví cold starts y permisos IAM, logrando **76/76** aserciones E2E sin fallos.
Tecnologías: AWS (EKS, Lambda, SNS, SQS, DynamoDB, RDS), Terraform, Kubernetes, FastAPI, Docker

### Experimentos de Arquitectura en Microservicios

MISW4202 Arquitecturas Ágiles de Software - 2026 - Universidad de los Andes
Experimentos guiados por hipótesis para un sistema de reservas: detección asíncrona de anomalías de pago en **538 ms** promedio vs. meta de 2 s (t-test, $p<0.001$) y detección del **100%** de ataques Man-in-the-Middle con 0 falsos positivos (JWT RS256 con revocación, RSA-OAEP, hash de integridad, TLS).
Tecnologías: Flask, Redis Streams, Celery, Nginx, JWT, RSA, SciPy

### Alarmas QR: de la Investigación UX a App Android + Web

Prototipado UX - MISO - 2026 - Universidad de los Andes
github.com/a-ortizp/alarmas-qr-app
Ciclo completo de producto: investigación con usuarios, **3 pruebas de usabilidad** (20 hallazgos), prototipo en Figma y design system Material 3 (48 componentes); luego app Android de **22 pantallas** (escaneo QR con ML Kit, alarmas con la app cerrada) y web Angular, con APK firmado vía GitHub Actions.
Tecnologías: Figma, Kotlin, Jetpack Compose, CameraX, ML Kit, Angular, GitHub Actions