Alejandro Ortiz Perdomo

MLOps Engineer | Machine Learning Engineer

Bogotá, Colombia | +57 319 666 3193 | alejortizp@gmail.com
LinkedIn: linkedin.com/in/alejandro-ortiz-perdomo-a35348116 | GitHub: github.com/alejortizp | Portafolio: alejortizp.github.io/curriculum_HV

RESUMEN PROFESIONAL

MLOps Engineer enfocado en llevar modelos de ML y LLMs **de los datos a producción**: pipelines de datos, entrenamiento reproducible, despliegue y monitoreo. Implementé **CI/CD** con **Databricks + MLflow** que redujo el despliegue de 2 semanas a **2 días** y monitoreo de **data/model drift** con reentrenamiento automático. Experiencia desplegando servicios en **Azure, AWS y GCP** con **Docker**, **Kubernetes (EKS)**, **Terraform** y serverless (**Azure Functions**, **Lambda**, **Cloud Run**), automatizados con **GitHub Actions**.

EXPERIENCIA LABORAL

AI Engineer - Torre IA

Periferia IT Group
06/2025 - Actualidad

- **Pipeline de búsqueda semántica CV-Oferta en producción:** Llevé a producción el pipeline de ingesta (**Azure Document Intelligence**) e indexación vectorial (**Azure AI Search**), empaquetado como **Azure Functions en Docker** con indexación incremental por SQL trigger y sincronización programada. Procesa **500+ CVs/día** y atiende **10k+ búsquedas/mes** con latencia **<200ms**.
- **Plataforma de agentes LLM (SRPA) multi-cloud:** Diseño técnico y documentación de una plataforma de agentes *plug-and-play* que automatiza el SDLC, con LLMs como **DeepSeek R-1** servidos en **Azure AI Foundry** y operada sobre **Azure / AWS / GCP** para uso interno y comercial; incluye generación automatizada de pruebas unitarias con cobertura >=**85%**.
- **Arquitecturas de referencia para producción:** Defino arquitecturas, estimaciones y dimensionamiento de equipos para llevar soluciones de **GenAI, Agentic AI y RAG** a producción en clientes enterprise (banca, seguros, retail, energía y telco).

AI Engineer Freelance - Clínica Odontológica

Freelance
07/2026 - 08/2026

- **Despliegue serverless de agentes LLM:** Llevé a producción dos agentes (**LangGraph** + **Azure OpenAI**) sobre **Azure Functions** con procesamiento por colas (poison-queue y deduplicación), persistencia en Table Storage y secretos en **Key Vault** con managed identity.
- **Integraciones y observabilidad:** Webhook de **WhatsApp Cloud API** con verificación HMAC, calendario **Outlook (Microsoft Graph)** con reintentos y rotación de tokens, y alertas en **Application Insights**. Lógica crítica determinista (bloqueo contra doble reserva) y desarrollo TDD con **118 tests**.

Machine Learning Engineer

Global Hitss
09/2023 - 06/2025

- **Ciclo MLOps completo en Databricks:** Llevé los modelos de los datos a producción: procesamiento con **PySpark** sobre **Delta Lake** gobernado con **Unity Catalog**, orquestación con **Databricks Workflows**, versionado y promoción en **MLflow Model Registry**, y serving por **endpoint** o **batch** según el caso de uso.
- **CI/CD y operación de modelos:** Implementé el pipeline CI/CD que redujo el despliegue de 2 semanas a **2 días**, con monitoreo automático de drift y reentrenamiento.
- **Agente RAG en producción:** Desplegué un agente conversacional con RAG (**LangChain**, **Azure OpenAI**, **FAISS**) que atiende **10k+ consultas/mes**.
- **Modelos en producción:** Productivicé el sistema *Next Best Offer* (Reinforcement Learning) con salida validada por **A/B testing**, y el modelo de churn con scores integrados al **CRM** para **50k+ clientes**.

Consultor Machine Learning
Grupo CINTE
08/2023 - 09/2023

- **Observabilidad ML:** Diseñé la metodología de monitoreo para detección de *data/model drift* con alertas automáticas de reentrenamiento, adoptada como estándar del equipo de ciencia de datos.
- **Optimización de inferencia:** Audité y optimicé modelos LightGBM y Random Forest, reduciendo tiempos de inferencia y costo computacional.

Data Scientist
NAE
03/2023 - 07/2023

- **Modelo de contactabilidad en operación:** Desarrollé y puse en operación un modelo **LightGBM** que prioriza ventanas horarias y canales para campañas de **100k+ contactos/mes**.

Data Scientist II
Xolit
05/2022 - 01/2023

- **Despliegue batch en producción:** Llevé los modelos a producción como procesos **batch** orquestados con **Apache Airflow** según la programación definida, entregando los scores a la operación de cobranza.
- **Monitoreo de modelos productivos:** Construí dashboards en **Power BI** para seguimiento de métricas de desempeño de los modelos en producción y KPIs de recaudo.
- **Modelos en operación:** Propensión de pago (alimenta **focos automáticos** de gestión de cartera), recomendación de franja horaria de contacto y segmentación de titulares por clustering.

Analista de Datos / BI
Savia Salud EPS
08/2018 - 04/2021

- **Pipelines ETL:** Diseñé y construí procesos ETL para consolidar datos de múltiples fuentes, garantizando integridad y trazabilidad de la información.
- **Business Intelligence:** Desarrollé dashboards estratégicos en **Qlik Sense** con KPIs operacionales y financieros para stakeholders clave.

EDUCACIÓN

Maestría en Ingeniería de Software
Universidad de los Andes
2025 - En proceso

Estadístico
Universidad del Valle
2011 - 2016

- Diplomado Ciencia de Datos (DS4A) - Correlation One, 2022
- Diplomado Deep Learning - Univ. Autónoma Occidente, 2023

CERTIFICACIONES

- AI-102: Microsoft Certified Azure AI Engineer Associate - Microsoft, Feb 2026
- NLP Specialization (RAG/Transformers) - Coursera, Jun 2025
- PyTorch Ultimate - Coursera, Mar 2025
- MLOps y Databricks - Netec, Dic 2024
- AWS Cloud Practitioner - Udemy, Feb 2022

HABILIDADES TÉCNICAS

- **GenAI & LLMs:** LangChain (Agents, RAG), LangGraph, Azure OpenAI (GPT-4, Embeddings), Prompt Engineering, Vector DBs (FAISS, Qdrant, Pinecone), LLM Evaluation (RAGAS)

- **Azure AI & Cloud:** Azure AI Search, Document Intelligence, Azure AI Foundry, Azure Functions, Databricks + MLflow (Workflows, Model Registry), Delta Lake, Unity Catalog
- **Google Cloud Platform (GCP):** Vertex AI (Training, Endpoints, Pipelines), Cloud Run, Pub/Sub, Compute Engine (MIG zonales), Cloud Storage, Cloud SQL
- **Amazon Web Services (AWS):** EKS, Lambda, DynamoDB, SNS, SQS, RDS
- **ML/DL Frameworks:** PyTorch, TensorFlow, Scikit-learn, XGBoost, LightGBM, Hugging Face Transformers
- **MLOps & Engineering:** Python, SQL, PySpark, Docker, CI/CD, Apache Airflow, Kubernetes, Terraform, Go, Angular, Kotlin, FastAPI, Streamlit, Git, GitHub Actions

HABILIDADES BLANDAS

Comunicación efectiva, Resolución de problemas, Pensamiento analítico, Trabajo en equipo, Adaptabilidad, Aprendizaje continuo, Gestión del tiempo, Liderazgo técnico

IDIOMAS

- Español: Nativo
- Inglés: Profesional (B2)

PROYECTOS

Asistente RAG con Web Scraping y Evaluación RAGAS

github.com/alejortizp/rag-banco
Asistente conversacional sobre el sitio público de un banco: crawler que respeta robots.txt, indexación en **Qdrant**, reranking con cross-encoder y memoria por sesión. Evaluado con **RAGAS** (50 preguntas, juez LLM independiente): faithfulness **0.87**; el reranker mejoró context utilization en **+8 pts** (A/B).
Tecnologías: Qdrant, Sentence-Transformers, Cross-Encoder, Groq Llama 3.1, RAGAS, Streamlit, Docker

Agente Email con LangChain

github.com/alejortizp/email-agent
Agente inteligente que consulta emails vía IMAP, clasifica con LLM y genera respuestas contextuales automáticas. Reduce tiempo de respuesta en **80%**.
Tecnologías: LangChain, Azure OpenAI, IMAP, Python, Prompt Engineering

NL-to-SQL/Pandas Agent

github.com/alejortizp/nl-to-code
Agente que traduce lenguaje natural a queries SQL y operaciones Pandas. Incluye validación de código, ejecución segura en sandbox y visualización automática de resultados.
Tecnologías: LangChain, SQL, Pandas, Code Interpreter, ReAct Pattern

Pipeline de ML con MLflow: Benchmark de 7 Modelos

github.com/alejortizp/MLOps-Pipeline-
Pipeline reproducible de regresión multivariada que compara **7 modelos** (Ridge, ElasticNet, Random Forest, Gradient Boosting, SVR, XGBoost, LightGBM) con búsqueda de hiperparámetros (RandomizedSearchCV, CV de 5 folds) y tracking en **MLflow**. El mejor modelo (Gradient Boosting, R^2 **0.84**) redujo el MAE en **26%** frente al baseline y se serializa como pipeline sklearn listo para inferencia.
Tecnologías: Scikit-learn, XGBoost, LightGBM, MLflow, Pandas, Joblib

Sistema MLOps de Clasificación de Texto

github.com/alejortizp/mlops-text-classification
Sistema MLOps para clasificar mensajes de soporte al cliente (dataset público de Twitter): pipelines de **entrenamiento**, **predicción por lotes** y **monitoreo** con alertas por umbral de accuracy, y reentrenamiento **campeón/retador** que solo promueve un modelo nuevo si supera al actual en el **MLflow Model Registry**. Modelo TF-IDF + CatBoost con accuracy **0.85**.
Tecnologías: MLflow, Model Registry, CatBoost, Scikit-learn, NLTK, TF-IDF, Pandas

PROYECTOS ACADÉMICOS

Plataforma de Monitorías en GCP (Go + Angular)

MISW4204 Desarrollo de Soluciones Cloud - 2026 - Universidad de los Andes
Principal contribuidor (**60%** de commits, equipo de 4). Migré el sistema de Docker Compose a **MIG con autoscaling + Load Balancer** y luego a **Cloud Run + Pub/Sub** serverless, con reportes PDF generados por IA de forma asíncrona. Pruebas de carga JMeter: **158 rps** (p95 292 ms) con **0%** errores de infraestructura; cobertura **84%** (Go) y **93%** (Angular); SonarQube A.
Tecnologías: Go (Gin), Angular, PostgreSQL, Cloud Run, Pub/Sub, Cloud SQL, OpenAI, JMeter, SonarQube, GitHub Actions

Marketplace de Envíos Event-Driven en AWS

MISW4301 Desarrollo de Apps en la Nube - 2026 - Universidad de los Andes
Lideré la arquitectura AWS e IaC de **11 microservicios** FastAPI (arquitectura hexagonal) sobre **EKS**, con extensión serverless: **SNS -> SQS** con DLQ, **4 Lambdas** en contenedor y DynamoDB, todo en **Terraform** desplegado con GitHub Actions a 5 ambientes. Resolví cold starts y permisos IAM, logrando **76/76** aserciones E2E sin fallos.
Tecnologías: AWS (EKS, Lambda, SNS, SQS, DynamoDB, RDS), Terraform, Kubernetes, FastAPI, Docker

Experimentos de Arquitectura en Microservicios

MISW4202 Arquitecturas Ágiles de Software - 2026 - Universidad de los Andes
Experimentos guiados por hipótesis para un sistema de reservas: detección asíncrona de anomalías de pago en **538 ms** promedio vs. meta de 2 s (t-test, $p<0.001$) y detección del **100%** de ataques Man-in-the-Middle con 0 falsos positivos (JWT RS256 con revocación, RSA-OAEP, hash de integridad, TLS).
Tecnologías: Flask, Redis Streams, Celery, Nginx, JWT, RSA, SciPy

Alarmas QR: de la Investigación UX a App Android + Web

Prototipado UX - MISO - 2026 - Universidad de los Andes
github.com/a-ortizp/alarmas-qr-app
Ciclo completo de producto: investigación con usuarios, **3 pruebas de usabilidad** (20 hallazgos), prototipo en Figma y design system Material 3 (48 componentes); luego app Android de **22 pantallas** (escaneo QR con ML Kit, alarmas con la app cerrada) y web Angular, con APK firmado vía GitHub Actions.
Tecnologías: Figma, Kotlin, Jetpack Compose, CameraX, ML Kit, Angular, GitHub Actions