# ALEJANDRO ORTIZ PERDOMO

## AI Engineer | Machine Learning Engineer

Bogotá, Colombia +57 319 666 3193 alejortizp@gmail.com
linkedin.com/in/alejandro-ortiz-perdomo-a35348116 | github.com/alejortizp |
alejortizp.github.io/curriculum_HV

## RESUMEN PROFESIONAL

AI Engineer con experiencia productizando soluciones de **GenAI/RAG** y **Agentic AI** en **Azure** y **GCP**. Especializado en diseño e implementación de **agentes inteligentes** (**LangChain**, **Azure OpenAI**, agentes **SRPA**) y arquitecturas de referencia para clientes enterprise. Track record procesando **10k+ consultas/mes** con agentes conversacionales y pipelines de matching semántico con **95%** de precisión. Combino Maestría en Ingeniería de Software (en curso) con base en Estadística para diseñar sistemas de IA escalables y listos para producción.

## EXPERIENCIA LABORAL

### AI Engineer — Torre IA
**Jun 2025 – Actualidad**
Periferia IT Group

- **Plataforma de Agentes IA (SRPA) para el SDLC:** Diseño técnico, conceptualización y documentación de un ecosistema propietario de agentes *Single-Responsibility Plug-and-play* que automatiza el ciclo de desarrollo end-to-end (onboarding, historias de usuario, asistencia en IDE, pruebas unitarias multi-lenguaje con cobertura ≥**85%**, QA, documentación y asistentes técnicos sobre LLMs como **DeepSeek R-1** en **Azure AI Foundry**). Plataforma multi-cloud (**Azure / AWS / GCP**) usada interna y comercialmente, con ramp-up **−70%** y ahorro de **60–70%** en el ciclo de desarrollo.
- **Sistema de Matching CV-Oferta:** Pipeline con **Azure Document Intelligence** + **AI Search**, desplegado como **Azure Functions en Docker**, que procesa 500+ CVs/día con **95%** de precisión en extracción y búsqueda semántica vectorial que reduce screening en **70%**. Productivo con **10k+ búsquedas/mes** y latencia <200ms.
- **Pre-ventas y Arquitectura de Soluciones:** Construyo estimaciones técnicas, dimensionamiento de equipos y arquitecturas de referencia para soluciones de **GenAI, Agentic AI y RAG** en clientes enterprise (banca, seguros,

## EDUCACIÓN

**Maestría en Ingeniería de Software**
Universidad de los Andes
2025 – En proceso

**Estadístico**
Universidad del Valle
2011 – 2016

**Diplomado Ciencia de Datos (DS4A)**
Correlation One, 2022

**Diplomado Deep Learning**
Univ. Autónoma Occidente, 2023

## IDIOMAS

**Español**
Nativo

**Inglés**
Profesional (B2)

## HABILIDADES CLAVE

Comunicación efectiva
Resolución de problemas
Pensamiento analítico
Trabajo en equipo
Adaptabilidad
Aprendizaje continuo
Gestión del tiempo
Liderazgo técnico

> retail, energía y telco). Lidero discovery técnico con stakeholders y posicionamiento del portafolio de agentes en anexos técnicos comerciales.

### AI Engineer Freelance — Clínica Odontológica

*Jul – Ago 2026*

Freelance

- **Agentes IA sobre WhatsApp:** Diseñé y desarrollé como único ingeniero dos agentes con **LangGraph** + **Azure OpenAI**: agendamiento de citas sincronizado con **Outlook (Microsoft Graph)**, con clasificación de intención por LLM y escalamiento de casos complejos; y recordatorios por categoría clínica con aprobación humana (*human-in-the-loop*).
- **Guardrails deterministas y despliegue serverless:** El LLM solo interpreta; la reserva la ejecuta código determinista con bloqueo que evita la doble reserva. Desplegado en **Azure Functions** (colas con poison-queue y deduplicación), Table Storage, **Key Vault** con managed identity y alertas en Application Insights; webhook de **WhatsApp Cloud API** con verificación HMAC. Desarrollo TDD con **118 tests**.

### Machine Learning Engineer

*Sep 2023 – Jun 2025*

Global Hitss

- **GenAI & RAG:** Diseñé e implementé agente conversacional con RAG que redujo tickets de soporte en **40%**, procesando **10k+ consultas/mes** con 85% de resolución sin escalamiento. Stack: LangChain, Azure OpenAI, FAISS.
- **MLOps en Databricks:** Ciclo completo de los datos a producción con **PySpark**, **Delta Lake** y **Unity Catalog**, orquestación con **Workflows**, versionado en **MLflow Model Registry** y serving por endpoint o batch. Pipeline CI/CD que redujo el deployment de 2 semanas a **2 días**, con monitoreo de drift y reentrenamiento automático.
- **Reinforcement Learning:** Productivicé sistema *Next Best Offer* (NBO) con A/B testing que incrementó conversión en **15%** y revenue de **$10k por persona**.
- **Modelo de Churn:** Desarrollé modelo predictivo con **Lift de 3.0** y recall del 82% en top decil, desplegado en Databricks e integrado al CRM para retención proactiva. Impactó **50k+ clientes**.

### Consultor Machine Learning

*Ago – Sep 2023*

Grupo CINTE

- **Observabilidad ML:** Diseñé metodología integral de monitoreo para detección de *data/model drift* con alertas automáticas de reentrenamiento, adoptada como estándar del equipo de ciencia de datos.
- **Optimización:** Audité y optimicé algoritmos LightGBM y Random Forest, mejorando eficiencia computacional y reduciendo tiempos de inferencia.

## CERTIFICACIONES

**AI-102: Microsoft Certified Azure AI Engineer Associate**
Microsoft, Feb 2026

**NLP Specialization** (RAG/Transformers)
Coursera, Jun 2025

**PyTorch Ultimate**
Coursera, Mar 2025

**MLOps y Databricks**
Netec, Dic 2024

**AWS Cloud Practitioner**
Udemy, Feb 2022

## HABILIDADES TÉCNICAS (años exp.)

### GENAI & LLMS

**LangChain** 2+ (Agents, RAG) | **LangGraph** 1+

**Azure OpenAI** 2+ (GPT-4, Embeddings)

**Prompt Engineering** 2+

**Vector DBs** 2+ (FAISS, Qdrant, Pinecone)

**LLM Evaluation** 1+ (RAGAS)

### AZURE AI & CLOUD

**Azure AI Search** 1+

**Document Intelligence** 1+

**Azure AI Foundry** 1+ | **Azure Functions** 1+

**Databricks + MLflow** 3+ (Workflows, Model Registry)

**Delta Lake** 1+ | **Unity Catalog** 1+

### GOOGLE CLOUD PLATFORM (GCP)

**Vertex AI** 1+ (Training, Endpoints, Pipelines)

**Cloud Run** 1+ | **Pub/Sub** 1+

**Compute Engine** 1+ (MIG zonales)

**Cloud Storage** 1+ | **Cloud SQL** 1+

### AMAZON WEB SERVICES (AWS)

**EKS** 1+ | **Lambda** 1+ | **DynamoDB** 1+

**SNS** 1+ | **SQS** 1+ | **RDS** 1+

### ML/DL FRAMEWORKS

**PyTorch** 2+ | **TensorFlow** 3+

**Scikit-learn** 4+ | **XGBoost** 4+ | **LightGBM** 4+

**Hugging Face Transformers** 2+

### Data Scientist
*Mar 2023 – Jul 2023*

NAE

- **Modelo de Contactabilidad:** Desarrollé modelo con **LightGBM** que incrementó tasa de contacto efectivo en **60%** (de 25% a 40%), optimizando ventanas horarias y canales. Impactó campañas con **100k+ contactos/mes**.

### Data Scientist II
*May 2022 – Ene 2023*

Xolit

- **Modelo de Propensión de Pago:** Desarrollé modelo predictivo de probabilidad de pago y acuerdo de cartera, maximizando el recaudo mediante **focos automáticos** de gestión priorizados por propensión.
- **Sistema de Recomendación:** Implementé motor de recomendación de franja horaria óptima de contacto por titular, incrementando la efectividad de la gestión de cobranza.
- **Segmentación de Clientes:** Diseñé estrategia de marketing basada en clustering de titulares, permitiendo comunicación personalizada por segmento para optimizar tasas de recaudo.
- **Producción y monitoreo:** Desplegué los modelos como procesos batch orquestados con **Apache Airflow** y construí dashboards en **Power BI** para seguimiento de KPIs de recaudo y métricas de desempeño de los modelos en producción.

### Analista de Datos / BI
*Ago 2018 – Abr 2021*

Savia Salud EPS

- **Business Intelligence:** Desarrollé dashboards estratégicos en **Qlik Sense** para toma de decisiones, brindando visibilidad de KPIs operacionales y financieros a stakeholders clave.
- **Pipelines ETL:** Diseñé y construí procesos ETL para consolidar datos de múltiples fuentes, garantizando integridad y trazabilidad de la información.
- **Gestión de Requerimientos:** Lideré levantamiento de requerimientos técnicos y funcionales con usuarios clave, alineando soluciones BI con objetivos organizacionales.

## PROYECTOS OPEN SOURCE

### 🏦 Asistente RAG con Web Scraping y Evaluación RAGAS
— github.com/alejortizp/rag-banco

Asistente conversacional sobre el sitio público de un banco: crawler que respeta robots.txt, indexación en **Qdrant**, reranking con cross-encoder y memoria por sesión. Evaluado con **RAGAS** (50 preguntas, juez LLM independiente): faithfulness **0.87**; el reranker mejoró context utilization en **+8 pts** (A/B).

**Stack:** Qdrant, Sentence-Transformers, Cross-Encoder, Groq Llama 3.1, RAGAS, Streamlit, Docker

### MLOPS & ENGINEERING

**Python** 7+ | **SQL** 7+ | **PySpark** 3+
**Docker** 2+ | **CI/CD** 2+
**Apache Airflow**
**Kubernetes** 1+ | **Terraform** 1+
**Go** 1+ | **Angular** 1+ | **Kotlin** 1+
**FastAPI** 3+ | **Streamlit** 3+
**Git** 4+ | **GitHub Actions** 2+

### 🤖 Agente Email con LangChain — github.com/alejortizp/email-agent

Agente inteligente que consulta emails vía IMAP, clasifica con LLM y genera respuestas contextuales automáticas. Reduce tiempo de respuesta en **80%**.

**Stack:** LangChain, Azure OpenAI, IMAP, Python, Prompt Engineering

### 💬 NL-to-SQL/Pandas Agent — github.com/alejortizp/nl-to-code

Agente que traduce lenguaje natural a queries SQL y operaciones Pandas. Incluye validación de código, ejecución segura en sandbox y visualización automática de resultados.

**Stack:** LangChain, SQL, Pandas, Code Interpreter, ReAct Pattern

## PROYECTOS ACADÉMICOS — MAESTRÍA (UNIANDES)

### ☁️ Plataforma de Monitorías en GCP (Go + Angular)

MISW4204 Desarrollo de Soluciones Cloud · 2026

Principal contribuidor (**60%** de commits, equipo de 4). Migré el sistema de Docker Compose a **MIG con autoscaling + Load Balancer** y luego a **Cloud Run + Pub/Sub** serverless, con reportes PDF generados por IA de forma asíncrona. Pruebas de carga JMeter: **158 rps** (p95 292 ms) con **0%** errores de infraestructura; cobertura **84%** (Go) y **93%** (Angular); SonarQube A.

**Stack:** Go (Gin), Angular, PostgreSQL, Cloud Run, Pub/Sub, Cloud SQL, OpenAI, JMeter, SonarQube, GitHub Actions

### 🚚 Marketplace de Envíos Event-Driven en AWS

MISW4301 Desarrollo de Apps en la Nube · 2026

Lideré la arquitectura AWS e IaC de **11 microservicios** FastAPI (arquitectura hexagonal) sobre **EKS**, con extensión serverless: **SNS→SQS** con DLQ, **4 Lambdas** en contenedor y DynamoDB, todo en **Terraform** desplegado con GitHub Actions a 5 ambientes. Resolví cold starts y permisos IAM, logrando **76/76** aserciones E2E sin fallos.

**Stack:** AWS (EKS, Lambda, SNS, SQS, DynamoDB, RDS), Terraform, Kubernetes, FastAPI, Docker

### 🛡️ Experimentos de Arquitectura en Microservicios

MISW4202 Arquitecturas Ágiles de Software · 2026

Experimentos guiados por hipótesis para un sistema de reservas: detección asíncrona de anomalías de pago en **538 ms** promedio vs. meta de 2 s (t-test, $p<0.001$) y detección del **100%** de ataques Man-in-the-Middle con 0 falsos positivos (JWT RS256 con revocación, RSA-OAEP, hash de integridad, TLS).

**Stack:** Flask, Redis Streams, Celery, Nginx, JWT, RSA, SciPy

### ⏰ Alarmas QR: de la Investigación UX a App Android + Web — github.com/a-ortizp/alarmas-qr-app

Prototipado UX · MISO · 2026

Ciclo completo de producto: investigación con usuarios, **3 pruebas de usabilidad** (20 hallazgos), prototipo en Figma y design system Material 3 (48 componentes); luego app Android de **22 pantallas** (escaneo QR con ML Kit, alarmas con la app cerrada) y web Angular, con APK firmado vía GitHub Actions.

**Stack:** Figma, Kotlin, Jetpack Compose, CameraX, ML Kit, Angular, GitHub Actions