Alejandro Ortiz Perdomo

AI Engineer | Machine Learning Engineer

Bogotá, Colombia | +57 319 666 3193 | alejortizp@gmail.com
LinkedIn: linkedin.com/in/alejandro-ortiz-perdomo-a35348116 | GitHub: github.com/alejortizp | Portafolio: alejortizp.github.io/curriculum_HV

RESUMEN PROFESIONAL

AI Engineer con experiencia productizando soluciones de **GenAI/RAG** y **Agentic AI** en **Azure** y **GCP**. Especializado en diseño e implementación de **agentes inteligentes** (**LangChain**, **Azure OpenAI**, agentes **SRPA**) y arquitecturas de referencia para clientes enterprise. Track record procesando **10k+ consultas/mes** con agentes conversacionales y pipelines de matching semántico con **95%** de precisión. Combino Maestría en Ingeniería de Software (en curso) con base en Estadística para diseñar sistemas de IA escalables y listos para producción.

EXPERIENCIA LABORAL

AI Engineer - Torre IA

Periferia IT Group
06/2025 - Actualidad

- **Plataforma de Agentes IA (SRPA) para el SDLC:** Diseño técnico, conceptualización y documentación de un ecosistema propietario de agentes *Single-Responsibility Plug-and-play* que automatiza el ciclo de desarrollo end-to-end (onboarding, historias de usuario, asistencia en IDE, pruebas unitarias multi-lenguaje con cobertura >=**85%**, QA, documentación y asistentes técnicos sobre LLMs como **DeepSeek R-1** en **Azure AI Foundry**). Plataforma multi-cloud (**Azure / AWS / GCP**) usada interna y comercialmente, con ramp-up **-70%** y ahorro de **60-70%** en el ciclo de desarrollo.
- **Sistema de Matching CV-Oferta:** Pipeline con **Azure Document Intelligence** + **AI Search**, desplegado como **Azure Functions en Docker**, que procesa 500+ CVs/día con **95%** de precisión en extracción y búsqueda semántica vectorial que reduce screening en **70%**. Productivo con **10k+ búsquedas/mes** y latencia <200ms.
- **Pre-ventas y Arquitectura de Soluciones:** Construyo estimaciones técnicas, dimensionamiento de equipos y arquitecturas de referencia para soluciones de **GenAI, Agentic AI y RAG** en clientes enterprise (banca, seguros, retail, energía y telco). Lidero discovery técnico con stakeholders y posicionamiento del portafolio de agentes en anexos técnicos comerciales.

AI Engineer Freelance - Clínica Odontológica

Freelance
07/2026 - 08/2026

- **Agentes IA sobre WhatsApp:** Diseñé y desarrollé como único ingeniero dos agentes con **LangGraph** + **Azure OpenAI**: agendamiento de citas sincronizado con **Outlook (Microsoft Graph)**, con clasificación de intención por LLM y escalamiento de casos complejos; y recordatorios por categoría clínica con aprobación humana (*human-in-the-loop*).
- **Guardrails deterministas y despliegue serverless:** El LLM solo interpreta; la reserva la ejecuta código determinista con bloqueo que evita la doble reserva. Desplegado en **Azure Functions** (colas con poison-queue y deduplicación), Table Storage, **Key Vault** con managed identity y alertas en Application Insights; webhook de **WhatsApp Cloud API** con verificación HMAC. Desarrollo TDD con **118 tests**.

Machine Learning Engineer

Global Hitss
09/2023 - 06/2025

- **GenAI & RAG:** Diseñé e implementé agente conversacional con RAG que redujo tickets de soporte en **40%**, procesando **10k+ consultas/mes** con 85% de resolución sin escalamiento. Stack: LangChain, Azure OpenAI, FAISS.
- **MLOps en Databricks:** Ciclo completo de los datos a producción con **PySpark**, **Delta Lake** y **Unity Catalog**, orquestación con **Workflows**, versionado en **MLflow Model Registry** y serving por endpoint o batch. Pipeline CI/CD que redujo el deployment de 2 semanas a **2 días**, con monitoreo de drift y reentrenamiento automático.
- **Reinforcement Learning:** Productivicé sistema *Next Best Offer* (NBO) con A/B testing que incrementó conversión en **15%** y revenue de **$10k por persona**.

• **Modelo de Churn:** Desarrollé modelo predictivo con **Lift de 3.0** y recall del 82% en top decil, desplegado en Databricks e integrado al CRM para retención proactiva. Impactó **50k+ clientes**.

Consultor Machine Learning
Grupo CINTE
08/2023 - 09/2023

• **Observabilidad ML:** Diseñé metodología integral de monitoreo para detección de *data/model drift* con alertas automáticas de reentrenamiento, adoptada como estándar del equipo de ciencia de datos.
• **Optimización:** Audité y optimicé algoritmos LightGBM y Random Forest, mejorando eficiencia computacional y reduciendo tiempos de inferencia.

Data Scientist
NAE
03/2023 - 07/2023

• **Modelo de Contactabilidad:** Desarrollé modelo con **LightGBM** que incrementó tasa de contacto efectivo en **60%** (de 25% a 40%), optimizando ventanas horarias y canales. Impactó campañas con **100k+ contactos/mes**.

Data Scientist II
Xolit
05/2022 - 01/2023

• **Modelo de Propensión de Pago:** Desarrollé modelo predictivo de probabilidad de pago y acuerdo de cartera, maximizando el recaudo mediante **focos automáticos** de gestión priorizados por propensión.
• **Sistema de Recomendación:** Implementé motor de recomendación de franja horaria óptima de contacto por titular, incrementando la efectividad de la gestión de cobranza.
• **Segmentación de Clientes:** Diseñé estrategia de marketing basada en clustering de titulares, permitiendo comunicación personalizada por segmento para optimizar tasas de recaudo.
• **Producción y monitoreo:** Desplegué los modelos como procesos batch orquestados con **Apache Airflow** y construí dashboards en **Power BI** para seguimiento de KPIs de recaudo y métricas de desempeño de los modelos en producción.

Analista de Datos / BI
Savia Salud EPS
08/2018 - 04/2021

• **Business Intelligence:** Desarrollé dashboards estratégicos en **Qlik Sense** para toma de decisiones, brindando visibilidad de KPIs operacionales y financieros a stakeholders clave.
• **Pipelines ETL:** Diseñé y construí procesos ETL para consolidar datos de múltiples fuentes, garantizando integridad y trazabilidad de la información.
• **Gestión de Requerimientos:** Lideré levantamiento de requerimientos técnicos y funcionales con usuarios clave, alineando soluciones BI con objetivos organizacionales.

EDUCACIÓN

Maestría en Ingeniería de Software
Universidad de los Andes
2025 - En proceso

Estadístico
Universidad del Valle
2011 - 2016

• Diplomado Ciencia de Datos (DS4A) - Correlation One, 2022
• Diplomado Deep Learning - Univ. Autónoma Occidente, 2023

CERTIFICACIONES

• AI-102: Microsoft Certified Azure AI Engineer Associate - Microsoft, Feb 2026
• NLP Specialization (RAG/Transformers) - Coursera, Jun 2025

- PyTorch Ultimate - Coursera, Mar 2025
- MLOps y Databricks - Netec, Dic 2024
- AWS Cloud Practitioner - Udemy, Feb 2022

HABILIDADES TÉCNICAS

- **GenAI & LLMs:** LangChain (Agents, RAG), LangGraph, Azure OpenAI (GPT-4, Embeddings), Prompt Engineering, Vector DBs (FAISS, Qdrant, Pinecone), LLM Evaluation (RAGAS)
- **Azure AI & Cloud:** Azure AI Search, Document Intelligence, Azure AI Foundry, Azure Functions, Databricks + MLflow (Workflows, Model Registry), Delta Lake, Unity Catalog
- **Google Cloud Platform (GCP):** Vertex AI (Training, Endpoints, Pipelines), Cloud Run, Pub/Sub, Compute Engine (MIG zonales), Cloud Storage, Cloud SQL
- **Amazon Web Services (AWS):** EKS, Lambda, DynamoDB, SNS, SQS, RDS
- **ML/DL Frameworks:** PyTorch, TensorFlow, Scikit-learn, XGBoost, LightGBM, Hugging Face Transformers
- **MLOps & Engineering:** Python, SQL, PySpark, Docker, CI/CD, Apache Airflow, Kubernetes, Terraform, Go, Angular, Kotlin, FastAPI, Streamlit, Git, GitHub Actions

HABILIDADES BLANDAS

Comunicación efectiva, Resolución de problemas, Pensamiento analítico, Trabajo en equipo, Adaptabilidad, Aprendizaje continuo, Gestión del tiempo, Liderazgo técnico

IDIOMAS

- Español: Nativo
- Inglés: Profesional (B2)

PROYECTOS

Asistente RAG con Web Scraping y Evaluación RAGAS

github.com/alejortizp/rag-banco
Asistente conversacional sobre el sitio público de un banco: crawler que respeta robots.txt, indexación en **Qdrant**, reranking con cross-encoder y memoria por sesión. Evaluado con **RAGAS** (50 preguntas, juez LLM independiente): faithfulness **0.87**; el reranker mejoró context utilization en **+8 pts** (A/B).
Tecnologías: Qdrant, Sentence-Transformers, Cross-Encoder, Groq Llama 3.1, RAGAS, Streamlit, Docker

Agente Email con LangChain

github.com/alejortizp/email-agent
Agente inteligente que consulta emails vía IMAP, clasifica con LLM y genera respuestas contextuales automáticas. Reduce tiempo de respuesta en **80%**.
Tecnologías: LangChain, Azure OpenAI, IMAP, Python, Prompt Engineering

NL-to-SQL/Pandas Agent

github.com/alejortizp/nl-to-code
Agente que traduce lenguaje natural a queries SQL y operaciones Pandas. Incluye validación de código, ejecución segura en sandbox y visualización automática de resultados.
Tecnologías: LangChain, SQL, Pandas, Code Interpreter, ReAct Pattern

Pipeline de ML con MLflow: Benchmark de 7 Modelos

github.com/alejortizp/MLOps-Pipeline-
Pipeline reproducible de regresión multivariada que compara **7 modelos** (Ridge, ElasticNet, Random Forest, Gradient Boosting, SVR, XGBoost, LightGBM) con búsqueda de hiperparámetros (RandomizedSearchCV, CV de 5 folds) y tracking en **MLflow**. El mejor modelo (Gradient Boosting, R^2 **0.84**) redujo el MAE en **26%** frente al baseline y se serializa como pipeline sklearn listo para inferencia.
Tecnologías: Scikit-learn, XGBoost, LightGBM, MLflow, Pandas, Joblib

Sistema MLOps de Clasificación de Texto

github.com/alejortizp/mlops-text-classification
Sistema MLOps para clasificar mensajes de soporte al cliente (dataset público de Twitter): pipelines de **entrenamiento**, **predicción por lotes** y **monitoreo** con alertas por umbral de accuracy, y reentrenamiento **campeón/retador** que solo promueve un modelo nuevo si supera al actual en el **MLflow Model Registry**. Modelo TF-IDF + CatBoost con accuracy **0.85**.
Tecnologías: MLflow, Model Registry, CatBoost, Scikit-learn, NLTK, TF-IDF, Pandas

PROYECTOS ACADÉMICOS

Plataforma de Monitorías en GCP (Go + Angular)

MISW4204 Desarrollo de Soluciones Cloud - 2026 - Universidad de los Andes
Principal contribuidor (**60%** de commits, equipo de 4). Migré el sistema de Docker Compose a **MIG con autoscaling + Load Balancer** y luego a **Cloud Run + Pub/Sub** serverless, con reportes PDF generados por IA de forma asíncrona. Pruebas de carga JMeter: **158 rps** (p95 292 ms) con **0%** errores de infraestructura; cobertura **84%** (Go) y **93%** (Angular); SonarQube A.
Tecnologías: Go (Gin), Angular, PostgreSQL, Cloud Run, Pub/Sub, Cloud SQL, OpenAI, JMeter, SonarQube, GitHub Actions

Marketplace de Envíos Event-Driven en AWS

MISW4301 Desarrollo de Apps en la Nube - 2026 - Universidad de los Andes
Lideré la arquitectura AWS e IaC de **11 microservicios** FastAPI (arquitectura hexagonal) sobre **EKS**, con extensión serverless: **SNS -> SQS** con DLQ, **4 Lambdas** en contenedor y DynamoDB, todo en **Terraform** desplegado con GitHub Actions a 5 ambientes. Resolví cold starts y permisos IAM, logrando **76/76** aserciones E2E sin fallos.
Tecnologías: AWS (EKS, Lambda, SNS, SQS, DynamoDB, RDS), Terraform, Kubernetes, FastAPI, Docker

Experimentos de Arquitectura en Microservicios

MISW4202 Arquitecturas Ágiles de Software - 2026 - Universidad de los Andes
Experimentos guiados por hipótesis para un sistema de reservas: detección asíncrona de anomalías de pago en **538 ms** promedio vs. meta de 2 s (t-test, $p<0.001$) y detección del **100%** de ataques Man-in-the-Middle con 0 falsos positivos (JWT RS256 con revocación, RSA-OAEP, hash de integridad, TLS).
Tecnologías: Flask, Redis Streams, Celery, Nginx, JWT, RSA, SciPy

Alarmas QR: de la Investigación UX a App Android + Web

Prototipado UX - MISO - 2026 - Universidad de los Andes
github.com/a-ortizp/alarmas-qr-app
Ciclo completo de producto: investigación con usuarios, **3 pruebas de usabilidad** (20 hallazgos), prototipo en Figma y design system Material 3 (48 componentes); luego app Android de **22 pantallas** (escaneo QR con ML Kit, alarmas con la app cerrada) y web Angular, con APK firmado vía GitHub Actions.
Tecnologías: Figma, Kotlin, Jetpack Compose, CameraX, ML Kit, Angular, GitHub Actions