ALEJANDRO ORTIZ PERDOMO

AI Engineer | Machine Learning Engineer

Bogotá, Colombia +57 319 666 3193 alejortizp@gmail.com
linkedin.com/in/alejandro-ortiz-perdomo-a35348116 | github.com/alejortizp |
alejortizp.github.io/curriculum_HV

RESUMEN PROFESIONAL

AI Engineer especializado en **GenAI/RAG**, **Agentic AI** y **LLMs** con track record productizando soluciones **multi-cloud (Azure, AWS, GCP)**. Experiencia end-to-end desde arquitectura y pre-ventas hasta deployment en producción con **MLOps**. Desarrollador de agentes inteligentes (**LangChain**, agentes **SRPA**) que automatizan workflows empresariales y aceleran el ciclo de desarrollo de software. Combino base matemática sólida (Estadística) con ingeniería de software moderna (CI/CD, Docker) para crear sistemas de IA escalables y confiables.

EXPERIENCIA LABORAL

AI Engineer — Torre IA
Jun 2025 – Actualidad
Periferia IT Group

- **Plataforma de Agentes IA (SRPA) para el SDLC:** Diseño técnico, conceptualización y documentación de un ecosistema propietario de agentes *Single-Responsibility Plug-and-play* que automatiza el ciclo de desarrollo end-to-end (onboarding, historias de usuario, asistencia en IDE, pruebas unitarias multi-lenguaje con cobertura ≥**85%**, QA, documentación y asistentes técnicos sobre LLMs como **DeepSeek R-1** en **Azure AI Foundry**). Plataforma multi-cloud (**Azure / AWS / GCP**) usada interna y comercialmente, con ramp-up **−70%** y ahorro de **60–70%** en el ciclo de desarrollo.
- **Sistema de Matching CV-Oferta:** Pipeline con **Azure Document Intelligence** + **AI Search**, desplegado como **Azure Functions en Docker**, que procesa 500+ CVs/día con **95%** de precisión en extracción y búsqueda semántica vectorial que reduce screening en **70%**. Productivo con **10k+ búsquedas/mes** y latencia <200ms.
- **Pre-ventas y Arquitectura de Soluciones:** Construyo estimaciones técnicas, dimensionamiento de equipos y arquitecturas de referencia para soluciones de **GenAI, Agentic AI y RAG** en clientes enterprise (banca, seguros,

EDUCACIÓN

Maestría en Ingeniería de Software
Universidad de los Andes
2025 – En proceso

Estadístico
Universidad del Valle
2011 – 2016

Diplomado Ciencia de Datos (DS4A)
Correlation One, 2022

Diplomado Deep Learning
Univ. Autónoma Occidente, 2023

IDIOMAS

Español
Nativo

Inglés
Profesional (B2)

HABILIDADES CLAVE

Comunicación efectiva
Resolución de problemas
Pensamiento analítico
Trabajo en equipo
Adaptabilidad
Aprendizaje continuo
Gestión del tiempo
Liderazgo técnico

> retail, energía y telco). Lidero discovery técnico con stakeholders y posicionamiento del portafolio de agentes en anexos técnicos comerciales.

AI Engineer Freelance — Clínica Odontológica

Jul – Ago 2026

Freelance

- **Agentes IA sobre WhatsApp:** Diseñé y desarrollé como único ingeniero dos agentes con **LangGraph** + **Azure OpenAI**: agendamiento de citas sincronizado con **Outlook (Microsoft Graph)**, con clasificación de intención por LLM y escalamiento de casos complejos; y recordatorios por categoría clínica con aprobación humana (*human-in-the-loop*).
- **Guardrails deterministas y despliegue serverless:** El LLM solo interpreta; la reserva la ejecuta código determinista con bloqueo que evita la doble reserva. Desplegado en **Azure Functions** (colas con poison-queue y deduplicación), Table Storage, **Key Vault** con managed identity y alertas en Application Insights; webhook de **WhatsApp Cloud API** con verificación HMAC. Desarrollo TDD con **118 tests**.

Machine Learning Engineer

Sep 2023 – Jun 2025

Global Hitss

- **GenAI & RAG:** Diseñé e implementé agente conversacional con RAG que redujo tickets de soporte en **40%**, procesando **10k+ consultas/mes** con 85% de resolución sin escalamiento. Stack: LangChain, Azure OpenAI, FAISS.
- **MLOps en Databricks:** Ciclo completo de los datos a producción con **PySpark**, **Delta Lake** y **Unity Catalog**, orquestación con **Workflows**, versionado en **MLflow Model Registry** y serving por endpoint o batch. Pipeline CI/CD que redujo el deployment de 2 semanas a **2 días**, con monitoreo de drift y reentrenamiento automático.
- **Reinforcement Learning:** Productivicé sistema *Next Best Offer* (NBO) con A/B testing que incrementó conversión en **15%** y revenue de **$10k por persona**.
- **Modelo de Churn:** Desarrollé modelo predictivo con **Lift de 3.0** y recall del 82% en top decil, desplegado en Databricks e integrado al CRM para retención proactiva. Impactó **50k+ clientes**.

Consultor Machine Learning

Ago – Sep 2023

Grupo CINTE

- **Observabilidad ML:** Diseñé metodología integral de monitoreo para detección de *data/model drift* con alertas automáticas de reentrenamiento, adoptada como estándar del equipo de ciencia de datos.
- **Optimización:** Audité y optimicé algoritmos LightGBM y Random Forest, mejorando eficiencia computacional y reduciendo tiempos de inferencia.

CERTIFICACIONES

AI-102: Microsoft Certified Azure AI Engineer Associate
Microsoft, Feb 2026

NLP Specialization (RAG/Transformers)
Coursera, Jun 2025

PyTorch Ultimate
Coursera, Mar 2025

MLOps y Databricks
Netec, Dic 2024

AWS Cloud Practitioner
Udemy, Feb 2022

HABILIDADES TÉCNICAS (años exp.)

GENAI & LLMS

LangChain 2+ (Agents, RAG) | **LangGraph** 1+

Azure OpenAI 2+ (GPT-4, Embeddings)

Prompt Engineering 2+

Vector DBs 2+ (FAISS, Qdrant, Pinecone)

LLM Evaluation 1+ (RAGAS)

AZURE AI & CLOUD

Azure AI Search 1+

Document Intelligence 1+

Azure AI Foundry 1+ | **Azure Functions** 1+

Databricks + MLflow 3+ (Workflows, Model Registry)

Delta Lake 1+ | **Unity Catalog** 1+

GOOGLE CLOUD PLATFORM (GCP)

Vertex AI 1+ (Training, Endpoints, Pipelines)

Cloud Run 1+ | **Pub/Sub** 1+

Compute Engine 1+ (MIG zonales)

Cloud Storage 1+ | **Cloud SQL** 1+

AMAZON WEB SERVICES (AWS)

EKS 1+ | **Lambda** 1+ | **DynamoDB** 1+

SNS 1+ | **SQS** 1+ | **RDS** 1+

ML/DL FRAMEWORKS

PyTorch 2+ | **TensorFlow** 3+

Scikit-learn 4+ | **XGBoost** 4+ | **LightGBM** 4+

Hugging Face Transformers 2+

Data Scientist
Mar 2023 – Jul 2023

NAE

- **Modelo de Contactabilidad:** Desarrollé modelo con **LightGBM** que incrementó tasa de contacto efectivo en **60%** (de 25% a 40%), optimizando ventanas horarias y canales. Impactó campañas con **100k+ contactos/mes**.

Data Scientist II
May 2022 – Ene 2023

Xolit

- **Modelo de Propensión de Pago:** Desarrollé modelo predictivo de probabilidad de pago y acuerdo de cartera, maximizando el recaudo mediante **focos automáticos** de gestión priorizados por propensión.
- **Sistema de Recomendación:** Implementé motor de recomendación de franja horaria óptima de contacto por titular, incrementando la efectividad de la gestión de cobranza.
- **Segmentación de Clientes:** Diseñé estrategia de marketing basada en clustering de titulares, permitiendo comunicación personalizada por segmento para optimizar tasas de recaudo.
- **Producción y monitoreo:** Desplegué los modelos como procesos batch orquestados con **Apache Airflow** y construí dashboards en **Power BI** para seguimiento de KPIs de recaudo y métricas de desempeño de los modelos en producción.

Analista de Datos / BI
Ago 2018 – Abr 2021

Savia Salud EPS

- **Business Intelligence:** Desarrollé dashboards estratégicos en **Qlik Sense** para toma de decisiones, brindando visibilidad de KPIs operacionales y financieros a stakeholders clave.
- **Pipelines ETL:** Diseñé y construí procesos ETL para consolidar datos de múltiples fuentes, garantizando integridad y trazabilidad de la información.
- **Gestión de Requerimientos:** Lideré levantamiento de requerimientos técnicos y funcionales con usuarios clave, alineando soluciones BI con objetivos organizacionales.

PROYECTOS OPEN SOURCE

🏦 Asistente RAG con Web Scraping y Evaluación RAGAS
— github.com/alejortizp/rag-banco

Asistente conversacional sobre el sitio público de un banco: crawler que respeta robots.txt, indexación en **Qdrant**, reranking con cross-encoder y memoria por sesión. Evaluado con **RAGAS** (50 preguntas, juez LLM independiente): faithfulness **0.87**; el reranker mejoró context utilization en **+8 pts** (A/B).

Stack: Qdrant, Sentence-Transformers, Cross-Encoder, Groq Llama 3.1, RAGAS, Streamlit, Docker

MLOPS & ENGINEERING

Python 7+ | **SQL** 7+ | **PySpark** 3+
Docker 2+ | **CI/CD** 2+
Apache Airflow
Kubernetes 1+ | **Terraform** 1+
Go 1+ | **Angular** 1+ | **Kotlin** 1+
FastAPI 3+ | **Streamlit** 3+
Git 4+ | **GitHub Actions** 2+

🤖 Agente Email con LangChain — github.com/alejortizp/email-agent

Agente inteligente que consulta emails vía IMAP, clasifica con LLM y genera respuestas contextuales automáticas. Reduce tiempo de respuesta en **80%**.

Stack: LangChain, Azure OpenAI, IMAP, Python, Prompt Engineering

💬 NL-to-SQL/Pandas Agent — github.com/alejortizp/nl-to-code

Agente que traduce lenguaje natural a queries SQL y operaciones Pandas. Incluye validación de código, ejecución segura en sandbox y visualización automática de resultados.

Stack: LangChain, SQL, Pandas, Code Interpreter, ReAct Pattern

PROYECTOS ACADÉMICOS — MAESTRÍA (UNIANDES)

☁️ Plataforma de Monitorías en GCP (Go + Angular)

MISW4204 Desarrollo de Soluciones Cloud · 2026

Principal contribuidor (**60%** de commits, equipo de 4). Migré el sistema de Docker Compose a **MIG con autoscaling + Load Balancer** y luego a **Cloud Run + Pub/Sub** serverless, con reportes PDF generados por IA de forma asíncrona. Pruebas de carga JMeter: **158 rps** (p95 292 ms) con **0%** errores de infraestructura; cobertura **84%** (Go) y **93%** (Angular); SonarQube A.

Stack: Go (Gin), Angular, PostgreSQL, Cloud Run, Pub/Sub, Cloud SQL, OpenAI, JMeter, SonarQube, GitHub Actions

🚚 Marketplace de Envíos Event-Driven en AWS

MISW4301 Desarrollo de Apps en la Nube · 2026

Lideré la arquitectura AWS e IaC de **11 microservicios** FastAPI (arquitectura hexagonal) sobre **EKS**, con extensión serverless: **SNS→SQS** con DLQ, **4 Lambdas** en contenedor y DynamoDB, todo en **Terraform** desplegado con GitHub Actions a 5 ambientes. Resolví cold starts y permisos IAM, logrando **76/76** aserciones E2E sin fallos.

Stack: AWS (EKS, Lambda, SNS, SQS, DynamoDB, RDS), Terraform, Kubernetes, FastAPI, Docker

🛡️ Experimentos de Arquitectura en Microservicios

MISW4202 Arquitecturas Ágiles de Software · 2026

Experimentos guiados por hipótesis para un sistema de reservas: detección asíncrona de anomalías de pago en **538 ms** promedio vs. meta de 2 s (t-test, $p<0.001$) y detección del **100%** de ataques Man-in-the-Middle con 0 falsos positivos (JWT RS256 con revocación, RSA-OAEP, hash de integridad, TLS).

Stack: Flask, Redis Streams, Celery, Nginx, JWT, RSA, SciPy

⏰ Alarmas QR: de la Investigación UX a App Android + Web — github.com/a-ortizp/alarmas-qr-app

Prototipado UX · MISO · 2026

Ciclo completo de producto: investigación con usuarios, **3 pruebas de usabilidad** (20 hallazgos), prototipo en Figma y design system Material 3 (48 componentes); luego app Android de **22 pantallas** (escaneo QR con ML Kit, alarmas con la app cerrada) y web Angular, con APK firmado vía GitHub Actions.

Stack: Figma, Kotlin, Jetpack Compose, CameraX, ML Kit, Angular, GitHub Actions