ALEJANDRO ORTIZ PERDOMO

MLOps Engineer | Machine Learning Engineer

Bogotá, Colombia +57 319 666 3193 alejortizp@gmail.com
linkedin.com/in/alejandro-ortiz-perdomo | github.com/alejortizp |
alejortizp.github.io/curriculum_HV

RESUMEN PROFESIONAL

MLOps Engineer enfocado en llevar modelos de ML y LLMs **de los datos a producción**: pipelines de datos, entrenamiento reproducible, despliegue y monitoreo. Implementé **CI/CD** con **Databricks + MLflow** que redujo el despliegue de 2 semanas a **2 días** y monitoreo de **data/model drift** con reentrenamiento automático. Experiencia desplegando servicios en **Azure, AWS y GCP** con **Docker**, **Kubernetes (EKS)**, **Terraform** y serverless (**Azure Functions**, **Lambda**, **Cloud Run**), automatizados con **GitHub Actions**.

EXPERIENCIA LABORAL

AI Engineer — Torre IA
Jun 2025 – Actualidad

Periferia IT Group

- **Pipeline de búsqueda semántica CV-Oferta en producción:** Llevé a producción el pipeline de ingesta (**Azure Document Intelligence**) e indexación vectorial (**Azure AI Search**), empaquetado como **Azure Functions en Docker** con indexación incremental por SQL trigger y sincronización programada. Procesa **500+ CVs/día** y atiende **10k+ búsquedas/mes** con latencia **<200ms**.
- **Plataforma de agentes LLM (SRPA) multi-cloud:** Diseño técnico y documentación de una plataforma de agentes *plug-and-play* que automatiza el SDLC, con LLMs como **DeepSeek R-1** servidos en **Azure AI Foundry** y operada sobre **Azure / AWS / GCP** para uso interno y comercial; incluye generación automatizada de pruebas unitarias con cobertura ≥**85%**.
- **Arquitecturas de referencia para producción:** Defino arquitecturas, estimaciones y dimensionamiento de equipos para llevar soluciones de **GenAI, Agentic AI y RAG** a producción en clientes enterprise (banca, seguros, retail, energía y telco).

EDUCACIÓN

Maestría en Ingeniería de Software
Universidad de los Andes
2025 – En proceso

Estadístico
Universidad del Valle
2011 – 2016

Diplomado Ciencia de Datos (DS4A)
Correlation One, 2022

Diplomado Deep Learning
Univ. Autónoma Occidente, 2023

IDIOMAS

Español
Nativo

Inglés
Profesional (B2)

HABILIDADES CLAVE

Comunicación efectiva
Resolución de problemas
Pensamiento analítico
Trabajo en equipo
Adaptabilidad
Aprendizaje continuo
Gestión del tiempo
Liderazgo técnico

AI Engineer Freelance — Clínica Odontológica

Jul – Ago 2026

Freelance

- **Despliegue serverless de agentes LLM:** Llevé a producción dos agentes (**LangGraph** + **Azure OpenAI**) sobre **Azure Functions** con procesamiento por colas (poison-queue y deduplicación), persistencia en Table Storage y secretos en **Key Vault** con managed identity.
- **Integraciones y observabilidad:** Webhook de **WhatsApp Cloud API** con verificación HMAC, calendario **Outlook (Microsoft Graph)** con reintentos y rotación de tokens, y alertas en **Application Insights**. Lógica crítica determinista (bloqueo contra doble reserva) y desarrollo TDD con **118 tests**.

Machine Learning Engineer

Sep 2023 – Jun 2025

Global Hitss

- **Ciclo MLOps completo en Databricks:** Llevé los modelos de los datos a producción: procesamiento con **PySpark** sobre **Delta Lake** gobernado con **Unity Catalog**, orquestación con **Databricks Workflows**, versionado y promoción en **MLflow Model Registry**, y serving por **endpoint** o **batch** según el caso de uso.
- **CI/CD y operación de modelos:** Implementé el pipeline CI/CD que redujo el despliegue de 2 semanas a **2 días**, con monitoreo automático de drift y reentrenamiento.
- **Agente RAG en producción:** Desplegué un agente conversacional con RAG (**LangChain**, **Azure OpenAI**, **FAISS**) que atiende **10k+ consultas/mes**.
- **Modelos en producción:** Productivicé el sistema *Next Best Offer* (Reinforcement Learning) con salida validada por **A/B testing**, y el modelo de churn con scores integrados al **CRM** para **50k+ clientes**.

Consultor Machine Learning

Ago – Sep 2023

Grupo CINTE

- **Observabilidad ML:** Diseñé la metodología de monitoreo para detección de *data/model drift* con alertas automáticas de reentrenamiento, adoptada como estándar del equipo de ciencia de datos.
- **Optimización de inferencia:** Audité y optimicé modelos LightGBM y Random Forest, reduciendo tiempos de inferencia y costo computacional.

Data Scientist

Mar 2023 – Jul 2023

NAE

- **Modelo de contactabilidad en operación:** Desarrollé y puse en operación un modelo **LightGBM** que prioriza ventanas horarias y canales para campañas de **100k+ contactos/mes**.

CERTIFICACIONES

AI-102: Microsoft Certified Azure AI Engineer Associate
Microsoft, Feb 2026

NLP Specialization (RAG/Transformers)
Coursera, Jun 2025

PyTorch Ultimate
Coursera, Mar 2025

MLOps y Databricks
Netec, Dic 2024

AWS Cloud Practitioner
Udemy, Feb 2022

HABILIDADES TÉCNICAS (años exp.)

GENAI & LLMS

LangChain 2+ (Agents, RAG) | **LangGraph** 1+

Azure OpenAI 2+ (GPT-4, Embeddings)

Prompt Engineering 2+

Vector DBs 2+ (FAISS, Qdrant, Pinecone)

LLM Evaluation 1+ (RAGAS)

AZURE AI & CLOUD

Azure AI Search 1+

Document Intelligence 1+

Azure AI Foundry 1+ | **Azure Functions** 1+

Databricks + MLflow 3+ (Workflows, Model Registry)

Delta Lake 1+ | **Unity Catalog** 1+

GOOGLE CLOUD PLATFORM (GCP)

Vertex AI 1+ (Training, Endpoints, Pipelines)

Cloud Run 1+ | **Pub/Sub** 1+

Compute Engine 1+ (MIG zonales)

Cloud Storage 1+ | **Cloud SQL** 1+

AMAZON WEB SERVICES (AWS)

EKS 1+ | **Lambda** 1+ | **DynamoDB** 1+

SNS 1+ | **SQS** 1+ | **RDS** 1+

ML/DL FRAMEWORKS

PyTorch 2+ | **TensorFlow** 3+

Scikit-learn 4+ | **XGBoost** 4+ | **LightGBM** 4+

Hugging Face Transformers 2+

Data Scientist II

May 2022 – Ene 2023

Xolit

- **Despliegue batch en producción:** Llevé los modelos a producción como procesos **batch** orquestados con **Apache Airflow** según la programación definida, entregando los scores a la operación de cobranza.
- **Monitoreo de modelos productivos:** Construí dashboards en **Power BI** para seguimiento de métricas de desempeño de los modelos en producción y KPIs de recaudo.
- **Modelos en operación:** Propensión de pago (alimenta **focos automáticos** de gestión de cartera), recomendación de franja horaria de contacto y segmentación de titulares por clustering.

Analista de Datos / BI

Ago 2018 – Abr 2021

Savia Salud EPS

- **Pipelines ETL:** Diseñé y construí procesos ETL para consolidar datos de múltiples fuentes, garantizando integridad y trazabilidad de la información.
- **Business Intelligence:** Desarrollé dashboards estratégicos en **Qlik Sense** con KPIs operacionales y financieros para stakeholders clave.

PROYECTOS OPEN SOURCE

🏦 Asistente RAG con Web Scraping y Evaluación RAGAS

— github.com/alejortizp/rag-banco

Asistente conversacional sobre el sitio público de un banco: crawler que respeta robots.txt, indexación en **Qdrant**, reranking con cross-encoder y memoria por sesión. Evaluado con **RAGAS** (50 preguntas, juez LLM independiente): faithfulness **0.87**; el reranker mejoró context utilization en **+8 pts** (A/B).

Stack: Qdrant, Sentence-Transformers, Cross-Encoder, Groq Llama 3.1, RAGAS, Streamlit, Docker

🤖 Agente Email con LangChain

— github.com/alejortizp/email-agent

Agente inteligente que consulta emails vía IMAP, clasifica con LLM y genera respuestas contextuales automáticas. Reduce tiempo de respuesta en **80%**.

Stack: LangChain, Azure OpenAI, IMAP, Python, Prompt Engineering

💬 NL-to-SQL/Pandas Agent

— github.com/alejortizp/nl-to-code

Agente que traduce lenguaje natural a queries SQL y operaciones Pandas. Incluye validación de código, ejecución segura en sandbox y visualización automática de resultados.

Stack: LangChain, SQL, Pandas, Code Interpreter, ReAct Pattern

MLOPS & ENGINEERING

Python 7+ | **SQL** 7+ | **PySpark** 3+
Docker 2+ | **CI/CD** 2+
Apache Airflow
Kubernetes 1+ | **Terraform** 1+
Go 1+ | **Angular** 1+ | **Kotlin** 1+
FastAPI 3+ | **Streamlit** 3+
Git 4+ | **GitHub Actions** 2+

PROYECTOS ACADÉMICOS — MAESTRÍA (UNIANDES)

☁️ Plataforma de Monitorías en GCP (Go + Angular)

MISW4204 Desarrollo de Soluciones Cloud · 2026

Principal contribuidor (**60%** de commits, equipo de 4). Migré el sistema de Docker Compose a **MIG con autoscaling + Load Balancer** y luego a **Cloud Run + Pub/Sub** serverless, con reportes PDF generados por IA de forma asíncrona. Pruebas de carga JMeter: **158 rps** (p95 292 ms) con **0%** errores de infraestructura; cobertura **84%** (Go) y **93%** (Angular); SonarQube A.

Stack: Go (Gin), Angular, PostgreSQL, Cloud Run, Pub/Sub, Cloud SQL, OpenAI, JMeter, SonarQube, GitHub Actions

🚚 Marketplace de Envíos Event-Driven en AWS

MISW4301 Desarrollo de Apps en la Nube · 2026

Lideré la arquitectura AWS e IaC de **11 microservicios** FastAPI (arquitectura hexagonal) sobre **EKS**, con extensión serverless: **SNS→SQS** con DLQ, **4 Lambdas** en contenedor y DynamoDB, todo en **Terraform** desplegado con GitHub Actions a 5 ambientes. Resolví cold starts y permisos IAM, logrando **76/76** aserciones E2E sin fallos.

Stack: AWS (EKS, Lambda, SNS, SQS, DynamoDB, RDS), Terraform, Kubernetes, FastAPI, Docker

🛡️ Experimentos de Arquitectura en Microservicios

MISW4202 Arquitecturas Ágiles de Software · 2026

Experimentos guiados por hipótesis para un sistema de reservas: detección asíncrona de anomalías de pago en **538 ms** promedio vs. meta de 2 s (t-test, $p<0.001$) y detección del **100%** de ataques Man-in-the-Middle con 0 falsos positivos (JWT RS256 con revocación, RSA-OAEP, hash de integridad, TLS).

Stack: Flask, Redis Streams, Celery, Nginx, JWT, RSA, SciPy

⏰ Alarmas QR: de la Investigación UX a App Android + Web

— github.com/a-ortizp/alarmas-qr-app

Prototipado UX · MISO · 2026

Ciclo completo de producto: investigación con usuarios, **3 pruebas de usabilidad** (20 hallazgos), prototipo en Figma y design system Material 3 (48 componentes); luego app Android de **22 pantallas** (escaneo QR con ML Kit, alarmas con la app cerrada) y web Angular, con APK firmado vía GitHub Actions.

Stack: Figma, Kotlin, Jetpack Compose, CameraX, ML Kit, Angular, GitHub Actions